

MATRIZ DE OPERACIONALIZACIÓN DE VARIABLES

Implementación de un Modelo de Machine Learning
para la Detección de Transacciones Fraudulentas y Anómalas
en Pagos Digitales de la Empresa TechSport

Gestión 2025

Ing. Ada Condori Callisaya

Noviembre 2025

Introducción

La **Matriz de Operacionalización de Variables** es un instrumento metodológico que permite traducir conceptos abstractos (variables) en elementos medibles y observables. Para cada variable se definen:

- **Definición conceptual:** Marco teórico que sustenta la variable
- **Definición operacional:** Cómo se medirá en la práctica
- **Dimensiones:** Componentes o aspectos de la variable
- **Indicadores:** Métricas cuantificables
- **Instrumento de medición:** Herramientas/métodos para recolectar datos
- **Escala de medición:** Tipo de dato (nominal, ordinal, intervalo, razón)

Datos Generales de la Investigación

Programa	Maestría en Dirección Estratégica en Ingeniería de Software
Universidad	UAGRM - Facultad de Ingeniería en Ciencias de la Computación y Telecomunicaciones
Autor	Ing. Ada Condori Callisaya
Periodo	Gestión 2025 (Noviembre 2025 - Enero 2026)
Tipo	Investigación Aplicada-Tecnológica
Enfoque	Cuantitativo
Diseño	Cuasiexperimental Retrospectivo con Grupo de Comparación
Población	15,492,846 transacciones de pago digitales (Gestión 2025)

VARIABLE DEPENDIENTE (VD)

Transacciones Fraudulentas y Anómalas en Pagos Digitales

Aspecto	Descripción
Tipo de Variable	Dependiente (Variable Madre según método AQP/CCA)
Definición Conceptual	Conjunto de transacciones de pago procesadas por TechSport que presentan comportamientos sospechosos, patrones atípicos o características asociadas a actividad fraudulenta, que pueden resultar en pérdidas económicas, chargebacks o afectación de la seguridad financiera de la plataforma.
Definición Operacional	Transacciones clasificadas mediante etiquetado binario (Fraude / No Fraude) según el proceso de revisión del equipo de contabilidad de TechSport, basado en: <ul style="list-style-type: none"> ▪ Chargebacks confirmados por instituciones financieras ▪ Disputas resueltas como fraude ▪ Reportes de usuarios afectados verificados ▪ Revisión manual de transacciones sospechosas Tiempo de etiquetado: 0 días (detección inmediata) hasta 5 meses (chargebacks tardíos)
Justificación Metodológica	El etiquetado retrospectivo (hasta 5 meses) refleja la naturaleza real del fraude financiero, donde los chargebacks aparecen semanas o meses después. Esto NO constituye data leakage, ya que las features del modelo utilizan únicamente información disponible al momento de la transacción.

Dimensiones e Indicadores de la Variable Dependiente

Tabla 1: Operacionalización de la Variable Dependiente:
Transacciones Fraudulentas y Anómalas

Dimensión	Indicador	Definición Operacional	Fórmula / Cálculo	Escala	Instrumento
DIMENSIÓN 1: PREVALENCIA Y DISTRIBUCIÓN DEL FRAUDE					
Frecuencia de fraude	Tasa de fraude detectado (%)	Porcentaje de transacciones identificadas como fraudulentas respecto al total de transacciones procesadas	$\frac{\text{Fraudes detectados}}{\text{Total transacciones}} \times 100$	Razón (continua)	Dataset histórico de TechSport
Impacto económico	Pérdidas económicas por fraude (USD)	Suma monetaria total de transacciones fraudulentas confirmadas	$\sum_{i=1}^n \text{Monto}_{\text{fraude}_i}$	Razón (continua)	Sistema de pagos + registros contables
Distribución temporal	Transacciones fraudulentas por período temporal	Cantidad de fraudes agrupados por hora del día, día de la semana, mes	Histograma de frecuencias por período	Razón (discreta)	Metadata transaccional (timestamp)
Distribución por canal	Tasa de fraude por canal (%)	Porcentaje de fraude en cada canal de pago (Web / App / POS)	$\frac{\text{Fraudes}_{\text{canal}}}{\text{Total}_{\text{canal}}} \times 100$	Razón (continua)	Metadata transaccional (campo channel)
Distribución por gateway	Tasa de fraude por pasarela (%)	Porcentaje de fraude en cada gateway de pago	$\frac{\text{Fraudes}_{\text{gateway}}}{\text{Total}_{\text{gateway}}} \times 100$	Razón (continua)	Metadata transaccional (campo gateway_id)
DIMENSIÓN 2: DESEMPEÑO DEL SISTEMA DE DETECCIÓN					
Exactitud global	Accuracy (Precisión global) (%)	Proporción de transacciones correctamente clasificadas (VP + VN) respecto al total	$\frac{VP+VN}{VP+VN+FP+FN} \times 100$	Razón (continua)	Matriz de confusión (scikit-learn)

Continúa en la siguiente página

Tabla 1 – Continuación de la página anterior

Dimensión	Indicador	Definición Operacional	Fórmula / Cálculo	Escala	Instrumento
Capacidad de detección	Recall / Sensibilidad (%)	Proporción de fraudes detectados correctamente respecto al total de fraudes reales	$\frac{VP}{VP+FN} \times 100$	Razón (continua)	Matriz de confusión
Precisión de alertas	Precision (Valor predictivo positivo) (%)	Proporción de alertas de fraude que son correctas respecto al total de alertas generadas	$\frac{VP}{VP+FP} \times 100$	Razón (continua)	Matriz de confusión
Balance precision-recall	F1-Score	Media armónica entre Precision y Recall, indicador principal de desempeño	$2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$	Razón (continua, 0-1)	Métricas de clasificación (scikit-learn)
Discriminación global	AUC-ROC (Área bajo curva ROC)	Capacidad del modelo de discriminar entre fraude y no fraude en todos los umbrales posibles	Integral de curva ROC (TPR vs FPR)	Razón (continua, 0-1)	Curva ROC (scikit-learn)
DIMENSIÓN 3: ANÁLISIS DE ERRORES DEL SISTEMA					
Falsos positivos	Tasa de falsos positivos (FPR) (%)	Proporción de transacciones legítimas incorrectamente clasificadas como fraude	$\frac{FP}{FP+VN} \times 100$	Razón (continua)	Matriz de confusión
Falsos negativos	Tasa de falsos negativos (FNR) (%)	Proporción de fraudes no detectados (clasificados como legítimos)	$\frac{FN}{FN+VP} \times 100$	Razón (continua)	Matriz de confusión
Fraudes no detectados	Cantidad absoluta de FN	Número de transacciones fraudulentas que el modelo no detectó	Conteo directo de falsos negativos	Razón (discreta)	Matriz de confusión

Tabla 1 – Continuación de la página anterior

Dimensión	Indicador	Definición Operacional	Fórmula / Cálculo	Escala	Instrumento
Rechazos incorrectos	Cantidad absoluta de FP	Número de transacciones legítimas rechazadas incorrectamente	Conteo directo de falsos positivos	Razón (discreta)	Matriz de confusión
DIMENSIÓN 4: VIABILIDAD OPERATIVA DEL MODELO					
Velocidad de clasificación	Tiempo de inferencia (ms)	Tiempo promedio que toma el modelo en clasificar una transacción	Promedio de tiempo de predicción por transacción	Razón (continua)	Logs de ejecución del modelo (Python <code>time</code>)
Complejidad computacional	Tamaño del modelo (MB)	Espacio en disco del modelo serializado	Tamaño del archivo .pkl o .joblib	Razón (continua)	Sistema operativo (1s -1h)

Leyenda de Abreviaturas

- **VP:** Verdaderos Positivos (fraudes correctamente detectados)
- **VN:** Verdaderos Negativos (transacciones legítimas correctamente clasificadas)
- **FP:** Falsos Positivos (transacciones legítimas clasificadas como fraude)
- **FN:** Falsos Negativos (fraudes no detectados)
- **FPR:** False Positive Rate (tasa de falsos positivos)
- **FNR:** False Negative Rate (tasa de falsos negativos)
- **TPR:** True Positive Rate (tasa de verdaderos positivos = Recall)

VARIABLE INDEPENDIENTE (VI)

Modelo de Machine Learning Implementado

Aspecto	Descripción
Tipo de Variable	Independiente (Solución propuesta según método CCA - .^"de Aporte)
Definición Conceptual	Algoritmo computacional basado en aprendizaje automático supervisado, capaz de analizar datos históricos de transacciones etiquetadas para identificar patrones asociados a fraude y predecir la probabilidad de que nuevas transacciones sean fraudulentas o legítimas.
Definición Operacional	<p>Modelo de clasificación binaria (Fraude / No Fraude) entrenado con dataset histórico de TechSport (gestión 2025), que genera:</p> <ul style="list-style-type: none"> ▪ Score de riesgo: Probabilidad continua [0,1] de que una transacción sea fraude ▪ Clasificación binaria: Etiqueta final basada en umbral optimizado (típicamente 0.5) ▪ Explicabilidad: Feature importance para auditoría y cumplimiento regulatorio
Justificación Técnica	<p>Se selecciona Random Forest como algoritmo principal por:</p> <ul style="list-style-type: none"> ▪ Alta interpretabilidad (importante para auditorías PCI DSS / GDPR) ▪ Manejo natural de features categóricas y numéricas ▪ Resistencia a overfitting mediante ensemble learning ▪ Balance entre desempeño y tiempo de desarrollo (2 meses)

Dimensiones e Indicadores de la Variable Independiente

Tabla 2: Operacionalización de la Variable Independiente: Modelo de Machine Learning

Dimensión	Indicador	Definición Operacional	Valores / Rango	Escala	Instrumento
DIMENSIÓN 1: ARQUITECTURA DEL MODELO					
Algoritmo seleccionado	Tipo de modelo ML	Algoritmo de clasificación implementado como modelo principal	Random Forest (principal)	Nominal	Código Python (scikit-learn)
Algoritmos alternativos	Modelos de referencia	Algoritmos implementados para comparación	SVM (baseline)	Nominal	Código Python
Tipo de aprendizaje	Paradigma de ML	Modalidad de entrenamiento del modelo	Supervisado (con etiquetas)	Nominal	Documentación técnica
Tipo de tarea	Naturaleza del problema	Categoría de problema de ML	Clasificación binaria	Nominal	Documentación técnica
DIMENSIÓN 2: CONFIGURACIÓN DE HIPERPARÁMETROS					
Número de estimadores	<code>n_estimators</code>	Cantidad de árboles de decisión en el ensemble de Random Forest	100 - 500 (optimizado por Grid Search)	Razón (discreta)	Logs de Grid Search (scikit-learn)
Profundidad máxima	<code>max_depth</code>	Profundidad máxima de cada árbol individual (control de overfitting)	10 - 20 (optimizado)	Razón (discreta)	Logs de Grid Search
Muestras mínimas split	<code>min_samples_split</code>	Número mínimo de muestras requeridas para dividir un nodo interno	2 - 10 (optimizado)	Razón (discreta)	Logs de Grid Search
Muestras mínimas hoja	<code>min_samples_leaf</code>	Número mínimo de muestras requeridas en un nodo hoja	1 - 5 (optimizado)	Razón (discreta)	Logs de Grid Search

Tabla 2 – *Continuación*

Dimensión	Indicador	Definición Operacional	Valores / Rango	Escala	Instrumento
DIMENSIÓN 3: METODOLOGÍA DE ENTRENAMIENTO					
División del dataset	Train/Validation/Test split	Proporción de datos asignados a cada conjunto	70% / 15% / 15% (estratificado)	Razón (continua)	Código Python (train_test_split)
Balanceo de clases	Técnica de balanceo	Método para equilibrar clases desbalanceadas	SMOTE o class_weight (adaptativo)	Nominal	Código Python (imblearn o scikit-learn)
Estrategia de validación	Método de validación	Técnica para evaluar generalización del modelo	Validación estratificada (70/15/15)	Nominal	Código Python
Justificación validación	Razón metodológica	Por qué se usa validación estratificada en vez de temporal	Dataset homogéneo de 2025 evita temporal drift (Carcillo et al., 2018)	Cualitativo	Documentación metodológica
DIMENSIÓN 4: INGENIERÍA DE CARACTERÍSTICAS (FEATURE ENGINEERING)					
Cantidad de features	Número total de features	Cantidad de características utilizadas para entrenar el modelo	Mínimo: 15 features	Razón (discreta)	Código Python (feature engineering)
Features básicas	Características originales	Variables directamente extraídas del dataset sin transformación	Monto, canal, gateway, tipo transacción, hora, día	Mixta (nominal + razón)	Dataset histórico

Tabla 2 – Continuación

Dimensión	Indicador	Definición Operacional	Valores / Rango	Escala	Instrumento
Features derivadas	Características calculadas	Variables generadas mediante feature engineering	Frecuencia_24h, ratio_monto, tiempo_desde_última, velocidad_trans, etc.	Razón (continua)	Scripts de feature engineering
Prevención data leakage	Verificación temporal	Todas las features usan solo información disponible al momento de la transacción	Sí (validado)	Binaria (Sí/No)	Revisión de código + documentación
Feature importance	Importancia relativa	Ranking de features según contribución al modelo	Top 10 features documentadas	Ordinal	Atributo <code>feature_importances_</code> de Random Forest
DIMENSIÓN 5: MÉTRICAS DE ENTRENAMIENTO					
Error de entrenamiento	Train accuracy	Exactitud del modelo en el conjunto de entrenamiento	Meta: $\geq 95\%$ (para evitar underfitting)	Razón (continua)	Logs de entrenamiento
Error de validación	Validation accuracy	Exactitud del modelo en el conjunto de validación	Meta: $\geq 90\%$ (evitar overfitting)	Razón (continua)	Logs de entrenamiento
Gap train-validation	Overfitting metric	Diferencia entre train accuracy y validation accuracy	Meta: $< 5\%$ (indicador de generalización)	Razón (continua)	Logs de entrenamiento
Tiempo de entrenamiento	Training time (minutos)	Duración del proceso de entrenamiento completo	Meta: < 120 minutos	Razón (continua)	Logs de ejecución (Python time)
DIMENSIÓN 6: VIABILIDAD DE IMPLEMENTACIÓN					

Tabla 2 – *Continuación*

Dimensión	Indicador	Definición Operacional	Valores / Rango	Escala	Instrumento
Tiempo de inferencia	Prediction time (ms)	Tiempo promedio para clasificar una transacción	Meta: < 200ms	Razón (continua)	Logs de predicción
Tamaño del modelo	Model size (MB)	Espacio en disco del modelo serializado	Meta: < 500 MB	Razón (continua)	Sistema operativo (1s -1h)
Escalabilidad	Throughput (trans./seg)	Cantidad de transacciones que el modelo puede procesar por segundo	Medido en pruebas de carga	Razón (continua)	Script de benchmark

VARIABLES INTERVINIENTES

Factores que pueden influir en la relación VI → VD

Tabla 3: Operacionalización de Variables Intervinientes

Variable	Indicador	Descripción	Valores	Escala
Canal de pago	payment_channel	Medio utilizado por el usuario para realizar el pago	Web / App Móvil / POS	Nominal
Tipo de transacción	transaction_type	Categoría de la operación de pago	Reserva / Membresía / Clínica / Car- go recurrente / One-time	Nominal
Gateway de pago	gateway_id	Pasarela de procesamiento utilizada	Stripe / CardConnect / Kushki / AzulPay / RazorPay / BAC / Otros	Nominal
Volumen transaccional	Transacciones/día	Cantidad promedio de transacciones procesadas por día	Variable (conteo dia- rio)	Razón (discreta)
País de origen	country_code	País del usuario según geolocalización IP	Códigos ISO (US, BR, AR, etc.)	Nominal
Horario de transacción	hour_of_day	Hora del día en que se realiza la transacción	0 - 23	Intervalo
Día de la semana	day_of_week	Día de la semana de la transacción	Lunes - Do- mingo (0-6)	Ordinal

Justificación de Variables Intervinientes

Estas variables NO son manipuladas directamente por el investigador, pero pueden influir en la relación entre el modelo de ML (VI) y la detección de fraude (VD). Por ejemplo:

- **Canal de pago:** Las transacciones en POS pueden tener patrones de fraude diferentes a las de App Móvil
- **Gateway:** Cada pasarela tiene controles de fraude propios que afectan la tasa base de fraude
- **Tipo de transacción:** Las membresías recurrentes pueden tener menor riesgo que pagos one-time de alto monto
- **Volumen transaccional:** En días de alta carga, algunos fraudes pueden pasar desapercibidos en el sistema actual

El modelo de ML debe aprender a identificar patrones de fraude **condicionados** por estas variables interviniientes.

Resumen Consolidado de Operacionalización

Tabla 4: Resumen de Variables, Dimensiones e Indicadores

Variable	Tipo	Dimensiones	Indicadores Clave	Instrumentos Principales
Transacciones Fraudulentas y Anómalas (VD)	Dependiente	4 dimensiones	<ul style="list-style-type: none"> ■ Tasa de fraude (%) ■ F1-Score ■ Recall (%) ■ Precision (%) ■ AUC-ROC 	<ul style="list-style-type: none"> ■ Dataset histórico ■ Matriz de confusión ■ Métricas scikit-learn
Modelo de Machine Learning (VI)	Independiente	6 dimensiones	<ul style="list-style-type: none"> ■ Algoritmo: Random Forest ■ Features: ≥ 15 ■ Tiempo inferencia: $<200\text{ms}$ ■ Hiperparámetros optimizados 	<ul style="list-style-type: none"> ■ Scripts Python ■ Logs de entrenamiento ■ Modelo serializado ■ GitHub repository
Factores Contextuales (Intervinientes)	Intervinientes	7 variables	<ul style="list-style-type: none"> ■ Canal de pago ■ Tipo de transacción ■ Gateway ■ Volumen diario 	<ul style="list-style-type: none"> ■ Metadata transaccional ■ Sistema de pagos

Metas Cuantificables de la Investigación

Objetivos Mínimos (Hipótesis a Validar)

Métrica	Objetivo Mínimo	Objetivo Óptimo
F1-Score	$\geq 85\%$	$\geq 90\%$
Recall (Sensibilidad)	$\geq 90\%$	$\geq 95\%$
Precision	$\geq 80\%$	$\geq 85\%$
AUC-ROC	≥ 0.92	≥ 0.95
Tiempo de inferencia	$<200\text{ms}$	$<100\text{ms}$
Número de features	≥ 15	≥ 20

Tabla 5: Metas Cuantificables del Modelo de Machine Learning

Comparación con Benchmarks de Literatura

El modelo será evaluado comparando sus métricas con benchmarks reportados en literatura científica del periodo 2020-2025:

- **Hafez et al. (2025):** F1-Score = 85-94 % (Random Forest en fraude de tarjetas)
- **Hernández Aros et al. (2024):** Precision = 85-92 % (ML en pagos digitales)

Criterio de éxito: El modelo alcanza desempeño comparable o superior a estos benchmarks, demostrando su efectividad en el contexto específico de pagos deportivos multicanal.

Instrumentos de Medición

Instrumentos Técnicos

1. Dataset Histórico de TechSport

- **Descripción:** Base de datos de transacciones de pago con etiquetado de fraude
- **Periodo:** Gestión 2025 (12 meses)
- **Tamaño:** 15,492,846 transacciones
- **Formato:** CSV o base de datos relacional
- **Variables incluidas:** Monto, canal, gateway, timestamp, etiqueta de fraude, etc.

2. Scripts de Python para Machine Learning

- **Librerías:** scikit-learn, pandas, numpy, matplotlib, seaborn
- **Funciones clave:**
 - `train_test_split()`: División de datos
 - `RandomForestClassifier()`: Modelo principal
 - `GridSearchCV()`: Optimización de hiperparámetros
 - `confusion_matrix()`: Matriz de confusión
 - `classification_report()`: Métricas de desempeño

3. Matriz de Confusión

- **Propósito:** Visualizar VP, VN, FP, FN
- **Herramienta:** scikit-learn + seaborn
- **Output:** Heatmap con conteos y porcentajes

4. Curva ROC

- **Propósito:** Evaluar capacidad de discriminación del modelo en todos los umbrales
- **Eje X:** False Positive Rate (FPR)
- **Eje Y:** True Positive Rate (TPR = Recall)
- **Métrica:** AUC-ROC (área bajo la curva)

5. Intervalos de Confianza mediante Bootstrap

- **Propósito:** Evaluar robustez estadística de las métricas
- **Método:** Bootstrap con 1000 muestras
- **Output:** IC del 95 % para F1-Score, Precision, Recall

6. Repositorio GitHub

- **Propósito:** Versionado de código y reproducibilidad
- **Contenido:** Scripts, notebooks, documentación, modelos serializados
- **Licencia:** MIT (código abierto)

Validación de Instrumentos

- **Validez del dataset:** Etiquetado realizado por equipo especializado de TechSport con criterios documentados (chargebacks, disputas, reportes)
 - **Fiabilidad de métricas:** Uso de librería scikit-learn (ampliamente validada en la comunidad científica)
 - **Reproducibilidad:** Código versionado en GitHub con requirements.txt y documentación técnica completa
-

Firma del Investigador

Ing. Ada Condori Callisaya
Maestrante - UAGRM
Fecha: _____

Firma del Tutor

[Nombre del Tutor]
Tutor de Tesis - UAGRM
Fecha: _____